Abstract in English

Context. Rare diseases collectively affect a substantial share of the population but their scarcity and heterogeneity make diagnosis, care coordination, and research structurally difficult. For ultra-rare conditions such as KCNB1-related developmental and epileptic encephalopathy (KCNB1-DEE), formal clinical knowledge remains sparse, and patients' families become key producers of knowledge about the disease. Part of this knowledge can be found in the narratives they share within patients' organizations' (POs) social media groups and other online spaces. This thesis investigates how natural language processing (NLP) methods can help identify, structure, represent and interpret these valuable narratives. All the work presented in this thesis was done in close partnership with *KCNB1 France*, and under a strict ethical and regulatory framework given the sensitivity of the data involved. The three main objectives are: (i) automatically detect *lived experiences* of the disease among posts mentioning DEEs, (ii) implement NER methods to automatically extract clinical and temporal entities, and (iii) improve representations of the narratives to identify meaningful thematic structures within narratives from *KCNB1 France* families.

Methods and data. Two complementary corpora were built and annotated for this purpose: one drawn from public online spaces mentioning DEEs, and one from *KCNB1 France*'s own social media groups. In order to answer to (i), we designed a context-driven annotation scheme distinguishing *lived experience* from informational, advocacy-oriented, and other disease-related content, and compared fine-tuned transformer models, zero-shot prompting, and synthetic data augmentation for this imbalanced classification task. Then, we applied the resulting classifier to the two corpora and compared discourse-type distributions across public and PO-based online spaces. For (ii), we first evaluated general-purpose and domain-adapted transformer models on a NER task targeting phenotype and treatment entities. Building on this preliminary evaluation, we then designed new, more fine-grained annotation guidelines and annotated a corpus restricted to *lived experience* narratives. We then compared rule-based, fine-tuned transformer, zero-shot span, and prompting-based extraction approaches. For (iii), we introduced a contrastive learning framework aligning text embeddings with lexicon-based symbolic views, and used the resulting representations to conduct a hybrid computational-qualitative analysis of *KCNB1 France* families' narratives.

Results. For (i), fine-tuned transformer models with augmented training data reliably distinguished *lived experience* content from other types of discourse. Applied on the two corpora, this classifier revealed a higher share of *lived experience* content in *KCNB1 France*'s groups than in public online spaces and some interesting temporal dynamics. For (ii), none of the nine extraction strategies compared reached a level of reliability suitable for further automated use or analysis. This weak performance was read as informative about the limits of imposing a fixed clinical entity inventory on *lived experience* narratives. For (iii), HMVCL considerably improved embedding space geometry and downstream clusterability. Building on these representations, the hybrid computational-qualitative analysis identified clinically and socially meaningful themes discussed by families on *KCNB1 France*'s online communities.

Conclusion. This thesis has two main contributions. At KCNB1-DEE level, it improved the scientific and medical knowledge of this ultra-rare disease. At a public health and methodological level, it showed that online narratives, especially the ones present on PO-led online spaces, are a valuable source of real-world data that can complement other sources of knowledge on rare diseases. However, their

meaningful use depends on collaborating with POs and clinicians, but also on adopting ethically responsible approaches and on acknowledging that no classification of these narratives, computational or qualitative, is a neutral description of the experience it draws on.

Title. From social media narratives to experiential knowledge: a NLP approach to analyzing family narratives in KCNB1-related developmental and epileptic encephalopathy.

Keywords. natural language processing, rare diseases, KCNB1, multi-view representation learning, lived experience, social media, digital public health

Abstract in French

Contexte. Les maladies rares touchent collectivement une part importante de la population, mais leur rareté et leur hétérogénéité compliquent structurellement le diagnostic, la coordination des soins et la recherche. Pour les maladies ultra-rares comme l'encéphalopathie épileptique et développementale liée au gène KCNB1 (KCNB1-DEE), les connaissances cliniques formelles restent limitées, et les familles de patient·es deviennent des productrices essentielles de savoirs sur la maladie. Une partie de ces savoirs se trouve dans les récits qu'elles partagent au sein des groupes de réseaux sociaux des associations de patients (*POs*) et d'autres espaces en ligne. Cette thèse examine comment le traitement automatique du langage naturel (*NLP*) peut aider à identifier, structurer, représenter et interpréter ces récits précieux. L'ensemble des travaux présentés dans cette thèse a été réalisé en étroite collaboration avec *KCNB1 France*, dans un cadre éthique et réglementaire strict compte tenu de la sensibilité des données concernées. Les trois objectifs principaux sont : (i) détecter automatiquement les *expériences vécues* de la maladie parmi les publications mentionnant les DEEs, (ii) mettre en œuvre des méthodes de reconnaissance d'entités nommées (*NER*) pour extraire automatiquement les entités cliniques et temporelles, et (iii) améliorer les représentations des récits afin d'identifier des structures thématiques significatives au sein des récits des familles de *KCNB1 France*.

Méthodes et données. Deux corpus complémentaires ont été constitués et annotés à cette fin : l'un issu d'espaces publics en ligne mentionnant les DEE, l'autre provenant des groupes de réseaux sociaux propres à *KCNB1 France*. Pour répondre à (i), nous avons conçu un guide d'annotation contextualisé distinguant l'*expérience vécue* des contenus informationnels, orientés vers la sensibilisation, ou autrement liés à la maladie, et comparé des modèles transformeurs *fine-tunés*, du *prompting zero-shot*, et de l'augmentation de données synthétiques pour cette tâche de classification déséquilibrée. Nous avons ensuite appliqué le classifieur obtenu aux deux corpus et comparé la distribution des types de discours entre espaces publics et espaces associatifs. Pour (ii), nous avons d'abord évalué des modèles transformeurs généralistes et spécialisés par domaine sur une tâche de *NER* ciblant les entités de phénotype et de traitement. En nous appuyant sur cette évaluation préliminaire, nous avons ensuite conçu un nouveau guide d'annotation plus fin et annoté un corpus restreint aux récits d'*expérience vécue*. Nous avons alors comparé des approches d'extraction à base de règles, par *fine-tuning* de transformeurs, par extraction *zero-shot* de spans, et par *prompting*. Pour (iii), nous avons introduit un cadre d'apprentissage contrastif alignant des *embeddings* textuels avec des vues symboliques basées sur des lexiques, et utilisé les représentations obtenues pour mener une analyse hybride, computationnelle et qualitative, des récits des familles de *KCNB1 France*.

Résultats. Pour (i), les modèles transformeurs *fine-tunés* entraînés sur des données augmentées ont permis de distinguer de manière fiable les contenus d'*expérience vécue* des autres types de discours. Appliqué aux deux corpus, ce classifieur a révélé une part plus importante de contenu d'*expérience vécue* au sein des groupes de *KCNB1 France* que dans les espaces publics en ligne, ainsi que des dynamiques temporelles intéressantes. Pour (ii), aucune des neuf stratégies d'extraction comparées n'a atteint un niveau de fiabilité suffisant pour un traitement ou une analyse automatisée ultérieurs. Cette performance globalement faible a été interprétée comme informative quant aux limites que pose l'imposition d'un inventaire fixe d'entités cliniques à des récits d'*expérience vécue*. Pour (iii), HMVCL a considérablement amélioré la géométrie de l'espace de représentation ainsi que la capacité de *clustering* en aval. En s'appuyant sur

ces représentations, l'analyse hybride computationnelle et qualitative a permis d'identifier des thèmes pertinents, tant cliniquement que socialement, discutés par les familles au sein des communautés en ligne de *KCNB1 France*.

Conclusion. Cette thèse apporte deux contributions principales. Au niveau de la KCNB1-DEE, elle a permis d'enrichir les connaissances scientifiques et médicales sur cette maladie ultra-rare. Sur le plan de la santé publique et de la méthodologie, elle a montré que les récits en ligne, en particulier ceux présents dans les espaces animés par des associations de patients, constituent une source précieuse de données de vie réelle pouvant compléter d'autres sources de connaissances sur les maladies rares. Toutefois, leur usage pertinent dépend d'une collaboration avec les associations de patients et les cliniciens, mais aussi de l'adoption d'approches éthiquement responsables et de la reconnaissance qu'aucune classification de ces récits, computationnelle ou qualitative, ne constitue une description neutre de l'expérience dont elle est issue.

Titre. Des récits de réseaux sociaux au savoir expérientiel : une approche NLP pour l'analyse du discours des familles dans l'encéphalopathie épileptique et développementale liée au gène KCNB1

Mots clés. traitement du langage naturel, maladies rares, KCNB1, apprentissage de représentations multi-vues, apprentissage contrastif, expérience vécue, réseaux sociaux, santé publique numérique, savoir expérientiel